

KcBERT: 한국어 댓글로 학습한 BERT

이준범
서울대학교
beomi@snu.ac.kr

KcBERT: Korean comments BERT

Junbum Lee
Seoul National University

요약

최근 자연어 처리에서는 사전 학습과 전이 학습을 통하여 다양한 과제에 높은 성능 향상을 성취하고 있다. 사전 학습의 대표적 모델로 구글의 BERT가 있으며, 구글에서 제공한 다국어 모델을 포함해 한국의 여러 연구기관과 기업에서 한국어 데이터셋으로 학습한 BERT 모델을 제공하고 있다. 하지만 이런 BERT 모델들은 사전 학습에 사용한 말뭉치의 특성에 따라 이후 전이 학습에서의 성능 차이가 발생한다. 본 연구에서는 소셜미디어에서 나타나는 구어체와 신조어, 특수문자, 이모지 등 일반 사용자들의 문장에 보다 유연하게 대응할 수 있는 한국어 뉴스 댓글 데이터를 통해 학습한 KcBERT를 소개한다. 본 모델은 최소한의 데이터 정제 이후 BERT WordPiece 토큰라이저를 학습하고, BERT Base 모델과 BERT Large 모델을 모두 학습하였다. 또한, 학습된 모델을 HuggingFace Model Hub에 공개하였다. KcBERT를 기반으로 전이 학습을 통해 한국어 데이터셋에 적용한 성능을 비교한 결과, 한국어 영화 리뷰 코퍼스(NSMC)에서 최고 성능의 스코어를 얻을 수 있었으며, 여타 데이터셋에서는 기존 한국어 BERT 모델과 비슷한 수준의 성능을 보였다.

주제어: 뉴스 댓글, 자연어처리, 언어 모델, 한국어 언어 모델, BERT

1. 서론

최근 NLP 연구에서는 큰 분량의 레이블 되지 않은 말뭉치를 통해 언어 모델을 학습하고, 이러한 사전 학습(Pretraining)을 거친 모델을 대상 데이터셋에 대해 전이 학습(Transfer learning, Fine tune)을 통해 높은 성능을 성취한다. 대표적인 모델로 구글에서 공개한 BERT(Bidirectional Encoder Representations from Transformers)[1]가 있으며, 이러한 Transformers[2]를 사용한 전이 학습 언어 모델들이 등장하고 있다. 한편, 이러한 연구는 언어 모델을 학습하기 위해 사용한 데이터셋에 종속적이다.[3] 구글 등에서 공개한 다국어 모델은 학습 데이터셋의 특성상 한국어의 비중이 낮다. 이로 인해 토큰라이저에서 글자 대부분이 음소 단위로 잘리는 등 한국어에 적합하지 않은 특성을 보이기도 한다. 따라서 한국어 말뭉치만으로 학습한 한국어 대형 언어 모델의 중요성이 대두되어, ETRI, SKT, TwoBlockAI, 서울대 등에서 KorBERT[4], KoBERT[5], HanBERT[6], KR-BERT[7] 등 다양한 한국어 BERT 모델을 공개했다. 하지만 현재 공개된 한국어 BERT 모델들은 대부분 한국어 위키피디아를 포함해 책과 온라인 뉴스 등 문어체 데이터를 기반으로 학습한 모델이다. 따라서 일반 사용자들이 작성하는 구어체, 오타와 신조어 등에 대해 모델이 상대적으로 대응하기 어려운 경우가 있다. 또한, 현재 공개된 대부분의 모델이 BERT Base 모델이며, Large 모델은 대부분 공개되지 않았다.

본 연구에서는 이를 해결하기 위해 한국어 댓글 데이터를 기반으로 학습한 KcBERT와 토큰라이저를 개발하였다. 학습 데이터로 2019년 1월 1일부터 2020년 06월 11일 자까지 네이버 뉴스 내 댓글 약 1억 1천만개를 수집하였다. 해당 데이터에 최소한의 전처리를 진행한 뒤 Huggingface의 BERT WordPiece 토큰라이저[8]를 학습하였고, BERT Base, Large 모델의 학습을 진행해 Huggingface의 Transformers[9] 허브에 오픈소스로 공개¹²하였다. 또한, 학습에 진행한 데이터셋을 캐글³과 깃헙⁴에 공개하였다.

2. 기존 연구

2.1 한국어 BERT 공개 모델

현재 공개된 한국어 BERT 모델에는 Google에서 공개한 Multilingual BERT, SKT에서 공개한 KoBERT, 서울대에 공개한 KR-BERT, TwoBlockAI에서 공개한 HanBERT, ETRI의 KorBERT 등이 있다.

한편, 위 모델들은 서로 다른 말뭉치로 토큰라이저 제작을 하고 BERT 사전 학습을 진행하였기 때문에 전이 학습 이후 테스트에서 성능 차이가 발생한다. 또한, 각자의 GitHub Repos-

¹<https://huggingface.co/beomi/kc Bert-base>

²<https://huggingface.co/beomi/kc Bert-large>

³<https://www.kaggle.com/junbumlee/kc Bert-pretraining-corpus-korean-news-comments>

⁴<https://github.com/Beomi/KcBERT>

itory에서 배포를 진행하거나 사용 협약서를 받는 등 일반 사용자들이 편리하게 접근해 사용하기에는 어려움이 따른다.

2.2 한국어 Transformer 계열 공개 모델

BERT 외에도 Transformer를 사용한 사전 학습 모델이 공개된 것이 몇 가지 있다. KoELECTRA[10], SKT AI의 KoGPT2[11] 등이 있다.

3. KcBERT 모델 학습

3.1 데이터셋

KcBERT는 네이버 뉴스 댓글 데이터로 학습을 진행하였다. 2019년 1월 1일 자부터 2020년 6월 11일 자까지 '랭킹 뉴스' 중, 연예/사진 단독 기사 분류를 제외한 모든 기사의 댓글과 대댓글을 수집해 사용하였다. 매일 새벽 2시 기준으로 전일자 랭킹뉴스에 해당하는 데이터를 수집하여, 총합 약 1억 5천만 개, 메타데이터를 제외한 순수 텍스트 기준 약 15GB의 댓글 데이터셋을 제작하였다.

3.2 학습 텍스트 정제

BERT 학습을 위해 아래와 같이 수집한 텍스트 데이터를 정제하였다.

1. 한글 및 영어, 특수문자, 그리고 유니코드 이모지를 제외한 글자를 제거
2. soynlp[12]를 사용해 댓글 내 중복 문자열 축약: 'ㅋㅋㅋㅋ'와 같은 중복된 글자를 두 글자 'ㅋㅋ'로 줄임
3. Cased 영대소문자 유지
4. 글자 단위 10글자 이하 제거
5. 중복 문장 제거

BERT Pretrain에는 위의 정제 과정을 거친 후 나온 약 8.9천만개, 약 12GB의 텍스트⁵를 사용하였다.

3.3 WordPiece 토큰나이저 학습

HuggingFace의 Tokenizers 라이브러리를 통해 BERT WordPiece 토큰나이저를 학습시켰다. 이때, 정제된 데이터(약 12GB)를 전체 사용할 경우 Tokenizers 라이브러리의 버그⁶로 토큰나이저 학습이 실패해, 날짜 기반으로 약 1/10의 데이터를 샘플링한 뒤 토큰나이저 학습을 진행하였다.

토큰나이저의 Vocab 수는 총 3만개로 진행하였으며, 이 중 6000개를 Alphabet allow 설정을 통해 한국어의 개별 문자를 가능한 많이 포함해 Out of Vocab이 최대한 발생하지 않도록 학습하였다.

⁵해당 데이터는 Github과 Kaggle에 공개하였다.

⁶Token Merge 단계에서 프로그램 강제종료되는 현상

3.4 학습 설정 및 환경

BERT논문과 동일한 모델 크기와 설정으로 Base 및 Large 모델을 학습하였으며, 구글 클라우드 플랫폼(이하 GCP)에서 제공하는 TPU v3-8으로 학습을 진행하였다.

뉴스 댓글의 길이가 최대 300글자인 제한이 있어, 모델의 Positional Embedding을 최대 300토큰 길이까지만 학습할 수 있었다.

3.4.1 Base 모델 학습 하이퍼 파라미터 설정

Base 모델을 학습한 설정값은 아래와 같다. 언급하지 않은 모든 설정값은 BERT 모델과 동일하다.

- Train Batch size: 128
- Learning rate: 2e-5
- Validation Batch size: 64
- Warm-up Steps: 10

Warm-up Steps의 경우, 보다 높은 값을 적용할 경우 초기 Loss 수렴이 보다 빠르게 진행된다.

3.4.2 Large 모델 학습 하이퍼 파라미터 설정

- Batch size: 128
- Learning rate: 5e-5
- Validation Batch size: 64
- Warm-up Steps: 300,000

Warm-up Steps을 설정하지 않거나 적은 값으로 설정할 경우, 초기에 Loss가 발산해 학습에 실패할 수 있다.

3.5 학습 결과 및 체크포인트

Base 모델과 Large 모델 모두 1M(100만) 스텝 부근까지 학습 후, Loss값이 가장 낮은 모델을 선택하였다. 1M 스텝 이후에는 뚜렷한 Loss 감소가 일어나지 않아, 해당 범위 내에서 체크포인트를 선정하였다. 최종적으로 선정된 체크포인트는 다음과 같다.

- Base Model: 990k step checkpoint
- Large Model: 970k step checkpoint

4. 한국어 Transformers 계열 모델 간 성능 비교

KcBERT Base모델과 Large 모델을 사용해 다양한 한국어 NLP 태스크에 대한 성능 평가를 진행하였다. 작업 기기는 RTX TITAN (24GB VRam) 환경에서 1GPU로 진행하였다. 표 1에서 볼 수 있는 것과 같이, KcBERT는 댓글의 특성이 가장 잘 나타나는 네이버 영화 리뷰 코퍼스(NSMC)에서 높은 성능을 보였으며, Large 모델의 경우 Accuracy 90.68로 현존하는 모델 중 가장 높은 성능을 보였다.

⁷<https://github.com/Beomi/KcBERT-Finetune>

	NSMC (acc)	Naver NER (F1)	PAWS (acc)	KorNLI (acc)	KorSTS (spearman)	Question Pair (acc)	KorQuaD (Dev)(EM/F1)
KcBERT-Base	89.62	84.34	66.95	74.85	75.57	93.93	60.25 / 84.39
KcBERT-Large	90.68	85.53	70.15	76.99	77.49	94.06	62.16 / 86.64
KoBERT	89.63	86.11	80.65	79.00	79.64	93.93	52.81 / 80.27
HanBERT	90.16	87.31	82.40	80.89	83.33	94.19	78.74 / 92.02
KoELECTRA-Base	90.21	86.87	81.90	80.85	83.21	94.20	61.10 / 89.59
XLM-Roberta-Base	89.49	86.26	82.95	79.92	79.09	93.53	64.70 / 88.94
DistilKoBERT	88.41	84.13	62.55	70.55	73.21	92.48	54.12 / 77.80

표 1. 한국어 Transformers 계열 모델 NLP 태스크 성능평가⁷

비교 대상 모델 중 가장 접근성이 높은 KoBERT와 비교할 경우 KcBERT Base와 Large 모두 NSMC와 Question Pair, KorQuaD 데이터셋에서 거의 동일하거나 더 높은 성능을 보여준다. 한편, PAWS 테스트를 포함한 일부 테스트에서는 타 모델에 대비해 낮은 성능을 보이기도 한다. 이는 다른 언어 모델들이 다양한 분야의 텍스트 데이터를 사용해 학습해 일반적인 지식이 보다 많이 포함되어 있는 것에 비해, KcBERT는 댓글만 학습했다는 점에 있어 모델이 학습한 지식이 상대적으로 부족할 수 있음을 추측할 수 있다.

5. 결론

사전 학습과 전이 학습을 통한 자연어 처리는 영어뿐 아니라 한국어를 대상으로도 뛰어난 성능을 보인다. 이번 연구에서는 대량의 한국어 댓글 데이터셋을 제작해 최초로 댓글만 학습 데이터로 사용한 BERT 사전 학습을 진행하였다. 이를 통해 만든 KcBERT 모델과 학습 데이터셋을 깃헙, 캐글, Huggingface Hub에 공개하였다. KcBERT를 사용한 전이 학습은 다양한 분야에서 기존의 한국어 BERT 모델들과 비등한 성능을 보이며, 댓글과 관련한 테스트 데이터셋에서는 특히 높은 성능을 보여 댓글 데이터를 통한 학습이 일반 사용자들이 작성하는 문서에 보다 적합할 수 있다는 것을 보였다. 단, 학습 데이터셋이 가진 다양성의 한계로 인해 BERT모델이 보다 보편적인 지식을 학습하지 못해 일부 테스트에는 상대적으로 낮은 성능을 보이는 것도 확인할 수 있었다.

이후 연구에서는 일반적인 데이터셋과 댓글 데이터셋 모두를 활용한 BERT 모델을 만들어, 보다 다양한 분야에서도 높은 성능 향상을 얻기를 기대한다.

감사의 글

KcBERT 학습에 사용한 GCP TPU는 Google의 TFRC 프로그램 지원을 받았습니다.

학습 코드 작성과 Huggingface 변환에 도움을 주신 박장원

(Monologg)님께 감사의 말을 전합니다.

참고문헌

- [1] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "Bert: Pre-training of deep bidirectional transformers for language understanding," *NAACL-HLT*, 2019.
- [2] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," *Advances in neural information processing systems*, pp. 5998–6008, 2017.
- [3] D. Jurafsky and J. H. Martin, *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*, 1st ed. USA: Prentice Hall PTR, 2000.
- [4] ETRI, "Korbert," http://aiopen.etri.re.kr/service_dataset.php, 2019.
- [5] SKTBrain, "Korean bert pre-trained cased (kobert)," <https://github.com/SKTBrain/KoBERT>, 2019.
- [6] TwoBlockAI, "Hanbert-54kn," <https://github.com/tbai2019/HanBert-54k-N>, 2019.
- [7] S. Lee, H. Jang, Y. Baik, S. Park, and H. Shin, "Kr-bert: A small-scale korean-specific language model," *ArXiv*, Vol. abs/2008.03979, 2020.
- [8] HuggingFace, "Tokenizers: Fast state-of-the-art tokenizers optimized for research and production," <https://github.com/huggingface/tokenizers>, 2020.
- [9] T. Wolf, L. Debut, V. Sanh, J. Chaumond, C. Delangue, A. Moi, P. Cistac, T. Rault, R. Louf, M. Funtowicz, J. Davison, S. Shleifer, P. von Platen, C. Ma, Y. Jernite, J. Plu, C. Xu, T. L. Scao, S. Gugger, M. Drame, Q. Lhoest, and A. M. Rush, "Huggingface's transformers: State-of-the-art natural language processing," 2019.

- [10] J. Park, “Koelectra: Pretrained electra model for korean,” <https://github.com/monologg/KoELECTRA>, 2020.
- [11] SKTAI, “Korean gpt-2 pretrained cased (kogpt2),” <https://github.com/SKT-AI/KoGPT2>, 2020.
- [12] H. Kim, “soynlp: 한국어 자연어처리를 위한 파이썬 라이브러리,” <https://github.com/lovit/soynlp>, 2020.